# Análisis Estadístico de Datasets

## Regresión y Clasificación

**Julián Hernández**
Universidad de Antioquia

> "Los datos son Dios la estadística su lenguaje"

Made with GAMMA

# Contenido

### PARTE I: Problema de Regresión

Análisis del Advertising Dataset

### PARTE II: Problema de Clasificación

Análisis del Titanic Dataset

### Conclusiones

Síntesis de los resultados obtenidos

Made with GAMMA

# Parte 1

## NOMBRE DE LA BASE DE DATOS

Advertising Dataset

## FUENTE

**https://www.kaggle.com/datasets/ashydulislam/advertising-dataset**

## DESCRIPCIÓN GENERAL

Base de datos que contiene información sobre gastos en publicidad en diferentes medios (TV, Radio, Periódico) y sus correspondientes ventas. Permite modelar la relación lineal entre inversión publicitaria y resultados comerciales mediante regresión.

## CONTEXTO

Problema de inferencia y modelación estadística orientado a cuantificar el impacto de las estrategias publicitarias en las ventas.

# Objetivo del Análisis

El análisis del "Advertising Dataset" busca comprender y cuantificar la relación entre la inversión en diferentes canales publicitarios y el volumen de ventas resultante. Esto nos permitirá optimizar las estrategias de marketing para maximizar el retorno de la inversión.

### Meta Principal

Determinar la efectividad de cada canal de publicidad en la generación de ventas.

### Variables Independientes

TV, Radio, Periódico: Gasto presupuestario en cada medio.

### Variable Dependiente

Ventas: La métrica de rendimiento que se busca predecir y optimizar.

Made with GAMMA

# Objetivo del Análisis

## OBJETIVO GENERAL

Desarrollar un modelo de regresión lineal que permita predecir las ventas en función de la inversión publicitaria en diferentes medios.

## OBJETIVOS ESPECÍFICOS

1. Cuantificar la relación entre cada medio publicitario y las ventas
2. Evaluar la capacidad predictiva del modelo
3. Identificar qué medios tienen mayor impacto en las ventas
4. Proporcionar recomendaciones para optimizar la asignación de presupuesto publicitario

## ENFOQUE ESTADÍSTICO

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$$

Made with GAMMA

# Variable Objetivo

## VARIABLE RESPUESTA

Sales (Ventas)

## DEFINICIÓN

Volumen de ventas (en miles de unidades) generado como resultado de la inversión publicitaria en diferentes medios.

## TIPO DE VARIABLE

Numérica Continua

## ROL EN EL MODELO

Variable dependiente (Y) que será predicha en función de las variables independientes (gastos publicitarios).

## INTERPRETACIÓN

Cada unidad representa mil unidades vendidas, permitiendo cuantificar el impacto directo de la publicidad en los resultados comerciales.

Made with GAMMA

# Diccionario de Variables

| Variable | Traducción | Descripción | Tipo de Variable |
|---|---|---|---|
| TV | Televisión | Gasto en publicidad televisiva (en miles de dólares) | Numérica Continua |
| Radio | Radio | Gasto en publicidad radiofónica (en miles de dólares) | Numérica Continua |
| Newspaper | Periódico | Gasto en publicidad en periódicos (en miles de dólares) | Numérica Continua |
| Sales | Ventas | Volumen de ventas (en miles de unidades) | Numérica Continua |

Made with GAMMA

# Dimensiones del Dataset

200

OBSERVACIONES

Número de registros

4

VARIABLES

3 independientes + 1 dependiente

- Sin valores faltantes
- Datos completos y listos para análisis
- Estructura rectangular (200 × 4)

Made with GAMMA

# Hipótesis de Estudio

### HIPÓTESIS 1: Impacto de TV en Ventas

$H_0 : \beta_1 = 0$ (El gasto en TV no tiene efecto significativo en las ventas)

$H_1 : \beta_1 \neq 0$ (El gasto en TV tiene efecto significativo en las ventas)

### HIPÓTESIS 2: Impacto de Radio en Ventas

$H_0 : \beta_2 = 0$ (El gasto en Radio no tiene efecto significativo en las ventas)

$H_1 : \beta_2 \neq 0$ (El gasto en Radio tiene efecto significativo en las ventas)

### HIPÓTESIS 3: Bondad de Ajuste del Modelo

$H_0 : R^2 = 0$ (El modelo no explica la variabilidad en las ventas)

$H_1 : R^2 > 0$ (El modelo explica significativamente la variabilidad en las ventas)

Made with GAMMA

# Muestra de los Datos

| TV | Radio | Newspaper | Sales |
|---|---|---|---|
| 230.1 | 37.8 | 69.2 | 22.1 |
| 44.5 | 39.3 | 45.1 | 10.4 |
| 17.2 | 45.9 | 69.3 | 9.3 |
| 151.5 | 41.3 | 58.5 | 18.5 |
| 180.8 | 10.8 | 58.4 | 12.9 |
| 8.7 | 48.9 | 75.0 | 7.2 |
| 57.0 | 32.8 | 23.5 | 11.8 |
| 120.2 | 19.6 | 15.2 | 13.2 |

Primeras 8 observaciones del dataset (n=200)

Made with GAMMA

# Distribución de Variables Numéricas

A continuación, se presentan los histogramas de las principales variables del *Advertising Dataset*, mostrando la frecuencia de los gastos en publicidad y las ventas resultantes.

Made with GAMMA

# Matriz de Correlación

La matriz de correlación visualiza la fuerza y dirección de la relación lineal entre las variables del Advertising Dataset, mostrando la interacción entre los gastos en publicidad y las ventas.

| Variable | TV | Radio | Newspaper | Sales |
|---|---|---|---|---|
| TV | 1 | 0.05 | 0.06 | 0.78 |
| Radio | 0.05 | 1 | 0.35 | 0.58 |
| Newspaper | 0.06 | 0.35 | 1 | 0.23 |
| Sales | 0.78 | 0.58 | 0.23 | 1 |

La variable TV muestra la correlación más fuerte con **Sales** (0.78), seguida de **Radio** (0.58). **Newspaper** tiene una correlación débil (0.23) con **Sales**, lo que sugiere un menor impacto en el volumen de ventas.

Made with GAMMA

# Modelo de Regresión Lineal Múltiple

## ESPECIFICACIÓN DEL MODELO

$$Sales = \beta_0 + \beta_1(TV) + \beta_2(Radio) + \beta_3(Newspaper) + \varepsilon$$

## INTERPRETACIÓN DE COEFICIENTES

**$\beta_0$: Intercepto**
Ventas base sin publicidad

**$\beta_1$: Gasto en TV**
Cambio en ventas por cada unidad adicional de gasto en TV

**$\beta_2$: Gasto en Radio**
Cambio en ventas por cada unidad adicional de gasto en Radio

**$\beta_3$: Gasto en Newspaper**
Cambio en ventas por cada unidad adicional de gasto en Newspaper

**$\varepsilon$: Término de error**
Variabilidad no explicada

## SUPUESTOS DEL MODELO

**Linealidad**
Relación lineal entre variables

**Independencia**
Observaciones independientes

**Homocedasticidad**
Varianza constante del error

**Normalidad**
Errores distribuidos normalmente

**No multicolinealidad**
Variables independientes no correlacionadas

## OBJETIVO

Estimar los parámetros β para predecir ventas y evaluar significancia estadística.

Made with GAMMA

# PARTE II: PROBLEMA DE CLASIFICACIÓN

## Titanic Dataset

Made with GAMMA

# Titanic Dataset

## NOMBRE DE LA BASE DE DATOS

Titanic Dataset

## FUENTE

**https://www.kaggle.com/datasets/titanic**

## DESCRIPCIÓN GENERAL

Base de datos histórica del naufragio del RMS Titanic en 1912. Contiene información sobre pasajeros (características demográficas, clase de viaje, tarifa pagada) y su estado de supervivencia. Permite modelar la probabilidad de supervivencia mediante técnicas de clasificación estadística.

## CONTEXTO

Problema de inferencia y modelación estadística orientado a identificar patrones de supervivencia basados en características individuales de los pasajeros.

Made with GAMMA

# Objetivo del Análisis

## OBJETIVO GENERAL

Desarrollar un modelo de clasificación que permita predecir la probabilidad de supervivencia de los pasajeros del Titanic en función de sus características demográficas y socioeconómicas.

## OBJETIVOS ESPECÍFICOS

01

Identificar factores determinantes en la supervivencia

02

Evaluar la capacidad predictiva del modelo de clasificación

03

Cuantificar el impacto de variables como edad, género y clase de viaje

04

Proporcionar insights sobre patrones de supervivencia históricos

## ENFOQUE ESTADÍSTICO

Regresión Logística y Árboles de Decisión

Made with GAMMA

# Variable Objetivo

## VARIABLE RESPUESTA: Survived (Supervivencia)

### DEFINICIÓN

Variable binaria que indica si un pasajero del Titanic sobrevivió al naufragio (1) o no (0).

### TIPO DE VARIABLE

Categórica Nominal Binaria

### VALORES

- 0: No sobrevivió (murió)
- 1: Sobrevivió

### ROL EN EL MODELO

Variable dependiente (Y) que será predicha mediante clasificación binaria en función de características del pasajero.

### NATURALEZA DEL PROBLEMA

Problema de clasificación binaria donde el objetivo es estimar la probabilidad de supervivencia $P(Y = 1|X)$ basada en características observables.

### DISTRIBUCIÓN ESPERADA

Desbalance de clases: aproximadamente 38% sobrevivió, 62% no sobrevivió.

Made with GAMMA

# Diccionario de Variables

| Variable | Descripción | Tipo de Variable |
|---|---|---|
| PassengerId | Identificador único del pasajero | Numérica Discreta |
| Survived | Indicador de supervivencia (0=No, 1=Sí) | Categórica Nominal |
| Pclass | Clase de viaje (1=Primera, 2=Segunda, 3=Tercera) | Categórica Ordinal |
| Name | Nombre del pasajero | Texto |
| Sex | Género del pasajero (male/female) | Categórica Nominal |
| Age | Edad en años | Numérica Continua |
| SibSp | Número de hermanos/cónyuge a bordo | Numérica Discreta |
| Parch | Número de padres/hijos a bordo | Numérica Discreta |
| Ticket | Número de boleto | Texto |
| Fare | Tarifa pagada en libras esterlinas | Numérica Continua |
| Cabin | Número de camarote | Texto |
| Embarked | Puerto de embarque (C/Q/S) | Categórica Nominal |

Made with GAMMA

# Dimensiones del Dataset

**891**

Observaciones (pasajeros)

**12**

Variables (11 independientes + 1 dependiente)

Información adicional:

- Algunos valores faltantes en Age, Cabin y Embarked
- Datos históricos del naufragio del Titanic (1912)
- Estructura rectangular (891 × 12)
- Desbalance de clases en variable objetivo

Made with GAMMA

# Hipótesis de Estudio

### HIPÓTESIS 1: Efecto del Género en Supervivencia

$H_0$: P(Supervivencia|Mujer) = P(Supervivencia|Hombre) (El género no afecta la supervivencia)

$H_1$: P(Supervivencia|Mujer) ≠ P(Supervivencia|Hombre) (El género afecta significativamente la supervivencia)

### HIPÓTESIS 2: Efecto de la Clase de Viaje en Supervivencia

$H_0$: P(Supervivencia|Pclass=1) = P(Supervivencia|Pclass=3) (La clase no afecta la supervivencia)

$H_1$: P(Supervivencia|Pclass=1) ≠ P(Supervivencia|Pclass=3) (La clase afecta significativamente la supervivencia)

### HIPÓTESIS 3: Efecto de la Edad en Supervivencia

$H_0$: β_Age = 0 (La edad no tiene efecto significativo en la supervivencia)

$H_1$: β_Age ≠ 0 (La edad tiene efecto significativo en la supervivencia)

Made with GAMMA

# Muestra de los Datos

| PassengerId | Survived | Pclass | Sex | Age | Fare |
|---|---|---|---|---|---|
| 1 | 0 | 3 | male | 22 | 7.25 |
| 2 | 1 | 1 | female | 38 | 71.28 |
| 3 | 1 | 3 | female | 26 | 7.92 |
| 4 | 1 | 1 | female | 35 | 53.10 |
| 5 | 0 | 3 | male | 35 | 8.05 |
| 6 | 0 | 3 | male | - | 8.46 |

Primeras 6 observaciones del dataset (n=891). Nota: '-' indica valor faltante

Made with GAMMA

# Distribución de Variables Clave

Visualización de la distribución inicial de las variables más relevantes en el dataset del Titanic.

## Distribución de Edad

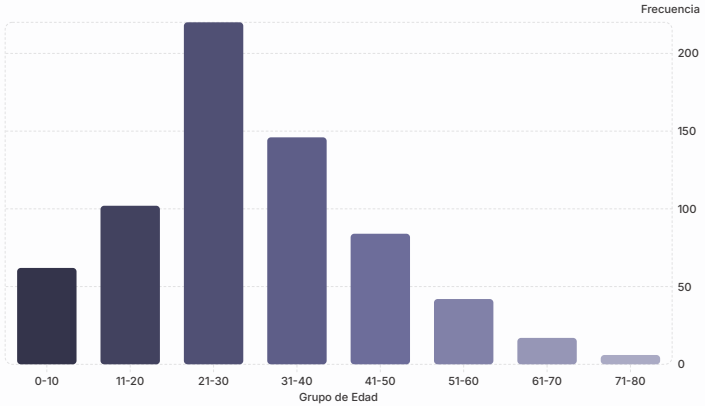


La mayoría de los pasajeros se encuentran en el rango de 21 a 30 años, reflejando una población joven a bordo.

## Distribución por Género

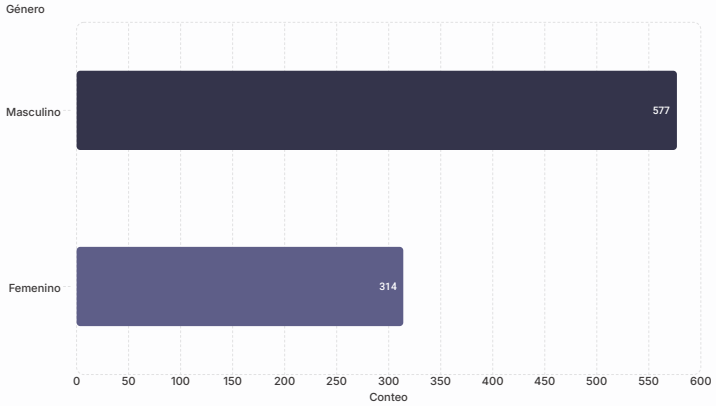


Hay una mayor proporción de pasajeros masculinos en el dataset, con casi el doble de hombres que de mujeres.

## Distribución por Clase de Viaje

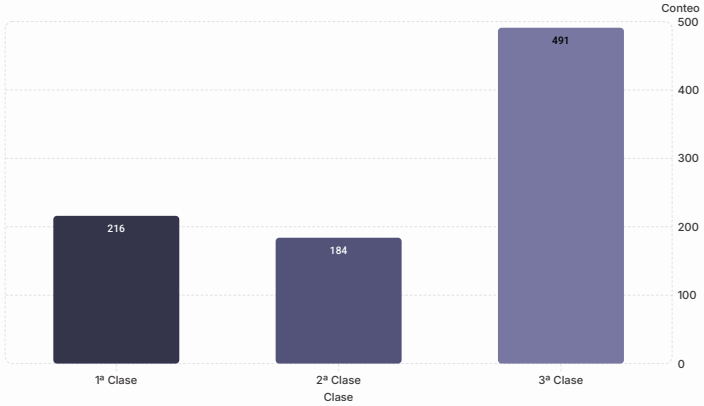


La 3ª clase era la más numerosa, con una cantidad significativamente mayor de pasajeros en comparación con la 1ª y 2ª clase.

## Distribución de Supervivencia

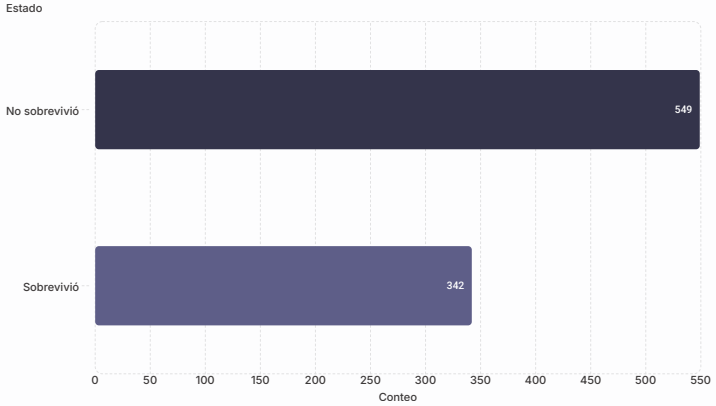


Los datos muestran un desbalance, con un número considerablemente mayor de pasajeros que no sobrevivieron en comparación con los que sí lo hicieron.

Made with GAMMA

# Análisis de Supervivencia por Género y Clase

Estos gráficos comparativos revelan patrones clave de supervivencia en el desastre del Titanic, destacando la influencia del género y la clase de viaje.

## Supervivencia por Género

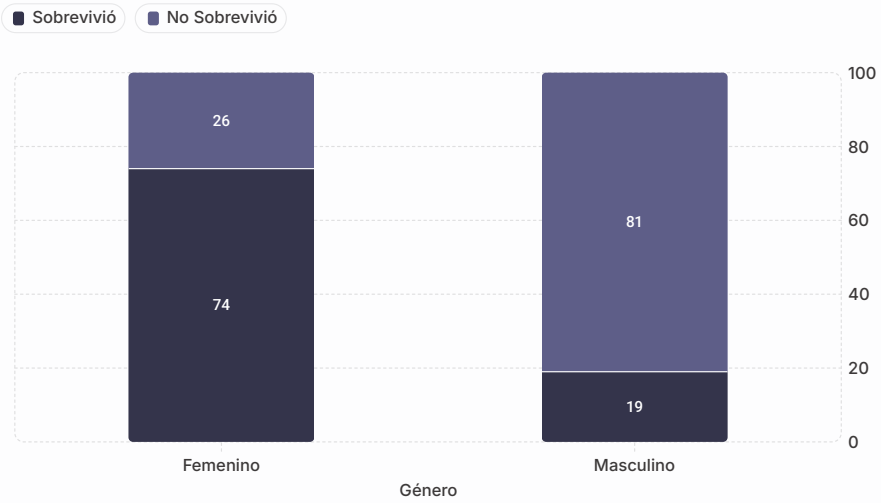


La proporción de mujeres que sobrevivieron fue significativamente mayor (74%) en comparación con los hombres (19%), evidenciando un sesgo en las operaciones de rescate.

## Supervivencia por Clase de Viaje

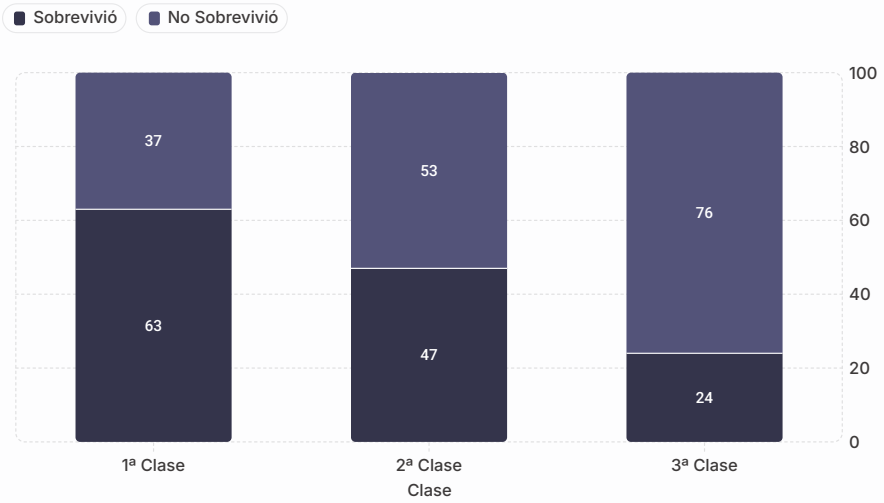


Los pasajeros de primera clase tuvieron una tasa de supervivencia mucho más alta (63%) que los de tercera clase (24%), lo que sugiere un impacto directo del estatus socioeconómico.

Made with GAMMA

# Modelos de Clasificación

Para abordar el problema de clasificación de supervivencia, exploraremos dos modelos predictivos clave:

## REGRESIÓN LOGÍSTICA

Modelo probabilístico que estima la probabilidad de supervivencia:

### Ventajas:

- Interpretable: coeficientes indican impacto de variables
- Probabilidades: proporciona estimaciones de probabilidad
- Eficiente: computacionalmente rápido

## ÁRBOLES DE DECISIÓN

Modelo no paramétrico que particiona el espacio de características:

- Divide recursivamente los datos basándose en variables
- Crea reglas de decisión interpretables
- Captura interacciones entre variables

### Ventajas:

- No requiere supuestos distribucionales
- Maneja variables categóricas naturalmente
- Proporciona importancia de variables

## COMPARACIÓN

Regresión Logística: Mejor para interpretación lineal

Árboles de Decisión: Mejor para capturar patrones complejos

Made with GAMMA

# Conclusiones

## SÍNTESIS DE HALLAZGOS

### REGRESIÓN (Advertising Dataset)

Variables más influyentes:

- TV: Correlación más fuerte con ventas (r=0.78)
- Radio: Correlación moderada (r=0.58)
- Newspaper: Correlación débil (r=0.23)

Implicación: La inversión en TV genera el mayor retorno en ventas, seguida de Radio.

### CLASIFICACIÓN (Titanic Dataset)

Variables más influyentes:

- Género: Mujeres tuvieron 74% de supervivencia vs 19% hombres
- Clase de viaje: 1ª clase 63% vs 3ª clase 24%
- Edad: Pasajeros más jóvenes tuvieron mayor supervivencia

Implicación: El género y la clase socioeconómica fueron determinantes en la supervivencia.

---

## DIFERENCIA ENTRE REGRESIÓN Y CLASIFICACIÓN

Regresión: Predice valores continuos (ventas)

Clasificación: Predice categorías discretas (sobrevivió/no sobrevivió)

---

## IMPORTANCIA DEL ANÁLISIS ESTADÍSTICO

> "Modelar es entender la realidad" - Los datos revelan patrones ocultos que guían decisiones estratégicas en negocios e investigación histórica.

Made with GAMMA

# Cierre

La estadística no interpreta, revela

**Julián Hernández**

**Universidad de Antioquia**

Made with GAMMA