# Documentación del dataset: Advertising Dataset

## a) Nombre de la base de datos

Advertising Dataset

## b) Fuente (URL)

https://www.kaggle.com/datasets/ashydv/advertising-dataset

## c) Descripción general del problema

El conjunto de datos corresponde a un problema clásico de modelación estadística supervisada, en el cual se busca analizar la relación entre la inversión en distintos medios publicitarios y el nivel de ventas alcanzado.

Desde una perspectiva inferencial y predictiva, el dataset permite estudiar cómo variables explicativas cuantitativas (gasto en publicidad) inciden sobre una variable respuesta continua (ventas), lo que lo convierte en un escenario idóneo para aplicar modelos de regresión, particularmente dentro del marco del modelo lineal clásico.

$$Y_{sales} = \beta_0 + \beta_1 TV + \beta_2 Radio + \beta_3 Newspaper + \epsilon$$

## d) Objetivo del análisis

El objetivo principal consiste en modelar y cuantificar la relación funcional entre la inversión en medios publicitarios (TV, radio y periódico) y las ventas, con el fin de:

- Estimar el efecto marginal de cada medio sobre las ventas.
- Evaluar la significancia estadística de los predictores.
- Construir un modelo predictivo que permita estimar las ventas a partir de niveles de inversión dados.

## e) Variable objetivo (variable respuesta)

- Nombre: Sales
- Tipo: Numérica continua

📌 Definición estadística:
Variable cuantitativa continua que representa el nivel de ventas del producto (usualmente expresado en miles de unidades). Se modela como variable dependiente $Y$ en un esquema de regresión.

## f) Diccionario de variables

| Variable | Descripción | Tipo de variable |
|---|---|---|
| TV | Inversión en publicidad en televisión (en miles de dólares) | continua |
| Radio | Inversión en publicidad en radio (en miles de dólares) | continua |
| Newspaper | Inversión en publicidad en periódicos (en miles de dólares) | continua |
| Sales | Ventas del producto (en miles de unidades) | continua |

📌 Precisión conceptual importante:

Aunque los datos pueden registrarse con cierta granularidad, todas las variables se tratan como continuas porque representan mediciones en escala de razón y admiten infinitos valores dentro de un intervalo.

## g) Número de observaciones

- n = 200 observaciones

## h) Número de variables

- p = 4 variables
  - 3 variables explicativas
  - 1 variable respuesta

## i) Posibles hipótesis de estudio

### ◆ Hipótesis 1: Efecto de la publicidad en TV

- $H_0: \beta_{TV} = 0$
- $H_1: \beta_{TV} \neq 0$

📌 Interpretación:
La inversión en televisión no tiene efecto significativo sobre las ventas vs. sí tiene efecto.

### ◆ Hipótesis 2: Comparación de impacto entre medios

- $H_0: \beta_{RADIO} = \beta_{NEWSPAPER}$
- $H_1: \beta_{RADIO} \neq \beta_{NEWSPAPER}$

📌 Interpretación:
El efecto marginal de la publicidad en radio es igual al de los periódicos vs. difiere entre ellos.

### ◆ Hipótesis 3: Significancia global del modelo

- $H_0: \beta_{TV} = \beta_{RADIO} = \beta_{NEWSPAPER}$
- $H_1: Al\ menos\ un\ \beta_j \neq 0$

📌 Interpretación:
Ninguna variable explicativa contribuye a explicar la variabilidad de las ventas vs. al menos una sí lo hace.