Documentación del dataset: Titanic Dataset

a) Nombre de la base de datos

Titanic Dataset

b) Fuente (URL)

https://www.kaggle.com/datasets/yasserh/titanic-dataset

c) Descripción general del problema

El conjunto de datos corresponde a un problema de clasificación supervisada binaria, cuyo objetivo es modelar la probabilidad de supervivencia de los pasajeros del Titanic en función de variables demográficas, socioeconómicas y operativas.

Desde una perspectiva estadística, se busca identificar patrones estructurales en los datos que permitan discriminar entre las dos clases de la variable respuesta (superviviente vs. no superviviente), mediante técnicas de modelación probabilística y algoritmos de clasificación.

d) Objetivo del análisis

El objetivo principal es construir un modelo de clasificación que permita predecir la probabilidad de supervivencia de un pasajero, así como identificar las variables que influyen significativamente en dicha probabilidad.

De manera específica, se busca:

- Determinar el efecto de variables como sexo, edad y clase socioeconómica sobre la supervivencia.
- Evaluar la capacidad predictiva de distintos modelos de clasificación.
- Analizar la relevancia estadística de los predictores en la discriminación de clases.

e) Variable objetivo (variable respuesta)

- Nombre: Survived
- Tipo: Categórica nominal (binaria)

📌 Definición estadística:
Variable cualitativa dicotómica que indica el estado de supervivencia del pasajero:

- 0 → No sobrevivió
- 1 → Sobrevivió

Se modela como variable dependiente Y en un contexto de clasificación.

f) Diccionario de variables

Variable	Descripción	Tipo de variable
PassengerId	Identificador único del pasajero	Numérica discreta (identificador, no analítica)
Survived	Indicador de supervivencia (0 = no, 1 = sí)	Categórica nominal
Pclass	Clase del pasajero (1 = alta, 2 = media, 3 = baja)	Categórica ordinal
Name	Nombre del pasajero	Categórica nominal (texto)
Sex	Sexo del pasajero	Categórica nominal
Age	Edad del pasajero (en años)	Numérica continua
SibSp	Número de hermanos/esposos a bordo	Numérica discreta
Parch	Número de padres/hijos a bordo	Numérica discreta
Ticket	Número de tiquete	Categórica nominal
Fare	Tarifa pagada por el pasaje	Numérica continua
Cabin	Número de cabina	Categórica nominal
Embarked	Puerto de embarque (C = Cherbourg, Q = Queenstown, S = Southampton)	Categórica nominal

📌 Nota técnica importante:
Variables como PassengerId, Name y Ticket suelen excluirse del modelado debido a su bajo valor predictivo directo o naturaleza identificadora.

g) Número de observaciones

- n = 891 observaciones

h) Número de variables

- p = 12 variables (incluyendo la variable respuesta)

i) Posibles hipótesis de estudio

Las siguientes hipótesis pueden formularse dentro de un marco de clasificación (por ejemplo, regresión logística):

◆ Hipótesis 1: Efecto del sexo sobre la supervivencia

- H_0: El sexo no tiene efecto sobre la probabilidad de supervivencia
- H_1: El sexo tiene un efecto significativo sobre la probabilidad de supervivencia

📌 Interpretación:
Se espera que la probabilidad de supervivencia difiera entre hombres y mujeres.

◆ Hipótesis 2: Influencia de la clase socioeconómica

- H_0: La clase del pasajero (Pclass) no influye en la supervivencia
- H_1: La clase del pasajero influye significativamente en la supervivencia

📌 Interpretación:
Pasajeros de clases más altas presentan mayor probabilidad de sobrevivir.

◆ Hipótesis 3: Relación entre edad y supervivencia

- H_0: La edad no está asociada con la probabilidad de supervivencia
- H_1: La edad está asociada con la probabilidad de supervivencia

📌 Interpretación:
Niños y adultos pueden presentar patrones diferenciados de supervivencia.